



# Tecnológico de Monterrey

Desarrollo de Aplicaciones Avanzadas de Ciencias Computacionales

Gpo 201

## **Docentes**

Benjamín Valdés Aguirre

Pedro Oscar Pérez Murueta

Manuel Casillas

## **Integrantes**

Diego Perdomo Salcedo

A01709150

Querétaro, Querétaro

<b>1.0 Entendimiento del Negocio</b>	<b>3</b>
<b>1.1 Contexto</b>	<b>3</b>
1.2 Objetivos de negocio y de minería de datos	3
1.2.1 Objetivo de Negocio	3
1.2.2 Criterios de éxito	3
1.2.3 Objetivo de minería de datos	3
1.2.4 Criterios de éxito	3
<b>2.0 Entendimiento de los datos</b>	<b>4</b>
2.1 Adquisición de datos	4
2.2 Caracterización del conjunto de datos	4
<b>3.0 Preparación de los Datos</b>	<b>4</b>
<b>4.0 Modelado</b>	<b>5</b>
4.1 Diseño de las Pruebas	5
4.2 Metricas	5
4.3 Modelo	7
4.4 Resultados	7
4.5 Validación de Objetivos	9
4.6 Hallazgos	10
4.6.1 Hallazgos extra solicitados por el Socio Formador	11
<b>5.0 Deployment</b>	<b>12</b>
<b>6.0 Comparación</b>	<b>13</b>
6.1 Modelos	13
6.1 Modelo Previo	13
6.2 Modelo Actual	13
6.2 Resultados y Hallazgos	14
mAP50 (B)	14
mAP50–95 (B)	14
6.3 Limitaciones y recomendaciones	16
6.4 Conclusiones	16

# 1.0 Entendimiento del Negocio

## 1.1 Contexto

El CAETEC (Campo Agro Experimental del Tec de Monterrey) es un laboratorio para el aprendizaje de actividades agropecuarias. Este cuenta con un establo con corrales destinados a las vacas que habitan esta área. Las vacas tienen varias actividades que llegan a realizar a lo largo de un día, tales como; socializar con otras vacas, comer, dormir en sus camas, y ser ordeñadas automáticamente por una máquina. En esta área del CAETEC una de sus prioridades es mantener a las vacas en un nivel alto de comodidad. Esto es porque mientras más cómodas se encuentren tienden a rendir una mayor cantidad y calidad de leche.

El sector lácteo enfrenta desafíos continuos en la optimización de sus procesos de ordeño. La eficiencia en este proceso no solo afecta la productividad de la granja, sino también el bienestar animal y la calidad de la leche. Este proyecto de ciencia de datos busca abordar estas cuestiones mediante el análisis avanzado de datos y la implementación de técnicas de visión por computadora.

## 1.2 Objetivos de negocio y de minería de datos

### 1.2.1 Objetivo de Negocio

Identificar el número de vacas en cada fila en un periodo de tiempo determinado.

### 1.2.2 Criterios de éxito

- ❖ Determinar con alta precisión la cantidad de vacas en una imagen. Arturo o Ivo determinarán si la precisión es satisfactoria.

### 1.2.3 Objetivo de minería de datos

Determinar la cantidad de vacas en cada imagen en cualquier condición.

### 1.2.4 Criterios de éxito

- ❖ Un modelo para condiciones diurnas con un 80% de precisión.
- ❖ Un modelo para condiciones nocturnas con un 50% de precisión

## 2.0 Entendimiento de los datos

### 2.1 Adquisición de datos

Se llevó a cabo utilizando una webcam Logitech instalada en el techo del corral, capturando imágenes desde una vista superior. Este enfoque permitió obtener datos visuales en ciclos continuos tanto de día como de noche. El conjunto de datos fue compartido y descargado mediante la plataforma OneDrive, garantizando un acceso centralizado y eficiente para el equipo de análisis.

Considerando que los datos fueron otorgados por el CAETEC no tuvimos problemas en adquirirlos.

### 2.2 Caracterización del conjunto de datos

Originalment el dataset contiene un aproximado de 8110 imágenes con resolución de 1920x1080, clasificados según el número de vacas presentes. La principal característica del conjunto es su variación extrema de iluminación, con imágenes muy oscuras o completamente negras durante la noche y alta luminosidad con posible sobreexposición en el día.

## 3.0 Preparación de los Datos

El etiquetado del dataset se hizo con segmentación, utilizando Bounding - Boxes para marcar la ubicación exacta de cada vaca en la imagen por medio de coordenadas y de esta forma contar la cantidad de vacas en la imagen.

Para asegurar la consistencia, se establecieron criterios específicos que definen cuándo se debe considerar la presencia de una vaca. Se determinó que una vaca debe ser contabilizada cuando al menos el 20% de su cuerpo es visible en la imagen. Por otro lado, se establecieron criterios claros para elementos que no deben ser considerados como vacas:

Criterios de Exclusión:

- Partes aisladas del animal (cola, pata, oreja)
- Personal de trabajo

- Desechos animales
- Aves en el entorno
- Sombras (de vacas o personas)
- Elementos del entorno (botas, escaleras, puertas)

## 4.0 Modelado

### 4.1 Diseño de las Pruebas

Para evaluar la calidad del modelo, dividimos el dataset en dos conjuntos principales: entrenamiento y validación. Esta división nos permite entrenar el modelo y validar su precisión de manera independiente. La distribución se realizó con aproximadamente 81% para entrenamiento (7,283 imágenes) y 19% para validación (1,658 imágenes), manteniendo una proporción que asegura suficientes datos para ambas fases.

La división del dataset se realizó manteniendo una estructura organizada:

- ❖ Entrenamiento: 7,283 imágenes
  - 6,469 imágenes con vacas
  - 1,218 imágenes de fondo
- ❖ Validación: 1,658 imágenes
  - 1,618 imágenes con vacas
  - 144 imágenes de fondo

Esta distribución asegura que tanto el conjunto de entrenamiento como el de validación contengan una mezcla representativa de imágenes con y sin vacas, permitiendo una evaluación robusta del rendimiento del modelo.

### 4.2 Metricas

El diseño de pruebas utiliza cuatro métricas fundamentales para validar el cumplimiento de nuestro objetivo de minería de datos.

**Objetivo de Minería de datos:**

- ❖ Determinar la cantidad de vacas en cada imagen en cualquier condición.
  - Un modelo para condiciones diurnas con un 80% de precisión.

- Un modelo para condiciones nocturnas con un 50% de precisión.

### **Métricas:**

#### ❖ **Precisión (P):**

- Mide el porcentaje de detecciones correctas entre todas las detecciones realizadas
- Nos ayuda a validar la exactitud de las predicciones del modelo
- Directamente relacionada con nuestros criterios de éxito de 80% para condiciones diurnas y 50% para nocturnas
- Un valor alto indica que el modelo tiene pocos falsos positivos

#### ❖ **Recall (R):**

- Indica la proporción de vacas reales que el modelo logra detectar
- Crucial para asegurar que no se están omitiendo vacas en el conteo
- Complementa la precisión para una evaluación más completa
- Un valor alto significa que el modelo raramente pasa por alto vacas presentes

#### ❖ **mAP50 (Mean Average Precision con IoU=50%):**

- Evalúa la precisión del modelo considerando un umbral de solapamiento del 50%
- Métrica estándar para evaluar la calidad de las detecciones
- Proporciona una visión general del rendimiento del modelo
- Útil para comparar con los umbrales de precisión establecidos en nuestros criterios

#### ❖ **mAP50-95:**


- Promedio de mAP en diferentes umbrales de IoU (de 50% a 95%)
- Evalúa la precisión de la localización de las detecciones
- Indica qué tan preciso es el modelo en diferentes niveles de exigencia
- Ayuda a validar la robustez general del modelo

Utilizando estas métricas podremos validar el objetivo de minería de datos adecuadamente. A pesar de que nuestro objetivo inicial era 50% de precisión con un modelo nocturno y 80% con un modelo diurno, con esto podremos cumplir con ambos a la vez, ya que el dataset utilizado contiene imágenes con ambos tipos de iluminación y se realizará un modelo generalizado.

### 4.3 Modelo

Para nuestro modelo se seleccionó **YOLO versión 8x**, que representa una variante más potente y sofisticada de la familia de detectores YOLO. YOLOv8x utiliza una arquitectura de red neuronal convolucional profunda con aproximadamente 68.2 M de parámetros, diseñada para maximizar la precisión en tareas de detección de objetos, ofreciendo un rendimiento en términos de exactitud y confiabilidad.

### 4.4 Resultados




Esta gráfica es la calificación general del modelo que combina dos aspectos importantes: qué tan preciso es cuando detecta algo y cuántas cosas puede detectar del total. Un F1-score alto significa que el modelo es bueno tanto encontrando objetos como asegurándose de que sus detecciones sean correctas.

Los resultados muestran que

- ❖ El modelo alcanza su mejor rendimiento con un F1 de 0.93 (93%) cuando se configura con un umbral de confianza de 0.493. Esto significa que el modelo está acertando en 93 de cada 100 casos en su punto óptimo.

- ❖ El rendimiento se mantiene estable hasta un umbral de confianza de 0.8. Esto demuestra que el modelo es robusto y flexible en su uso.
  - Adicionalmente, demuestra que es posible ajustar el nivel de confianza en un rango amplio sin perder rendimiento.
  - La caída después de 0.8 es natural y esperada, ya que el modelo se vuelve demasiado selectivo.



Esta matriz muestra las mismas relaciones que la matriz anterior pero en porcentajes o proporciones (de 0 a 1), lo que permite entender mejor la tasa de éxito del modelo independientemente del número total de casos.

Los resultados muestran que:

- ❖ Tasa de verdaderos positivos (esquina superior izquierda): de todas las vacas reales, el modelo identifica correctamente el 97%.
- ❖ Tasa de falsos positivos (esquina superior derecha): de todos los objetos que el modelo identifica como vacas en el fondo, el error es del 100%. Sugiere que el modelo tiende a sobredetectar en áreas de fondo.



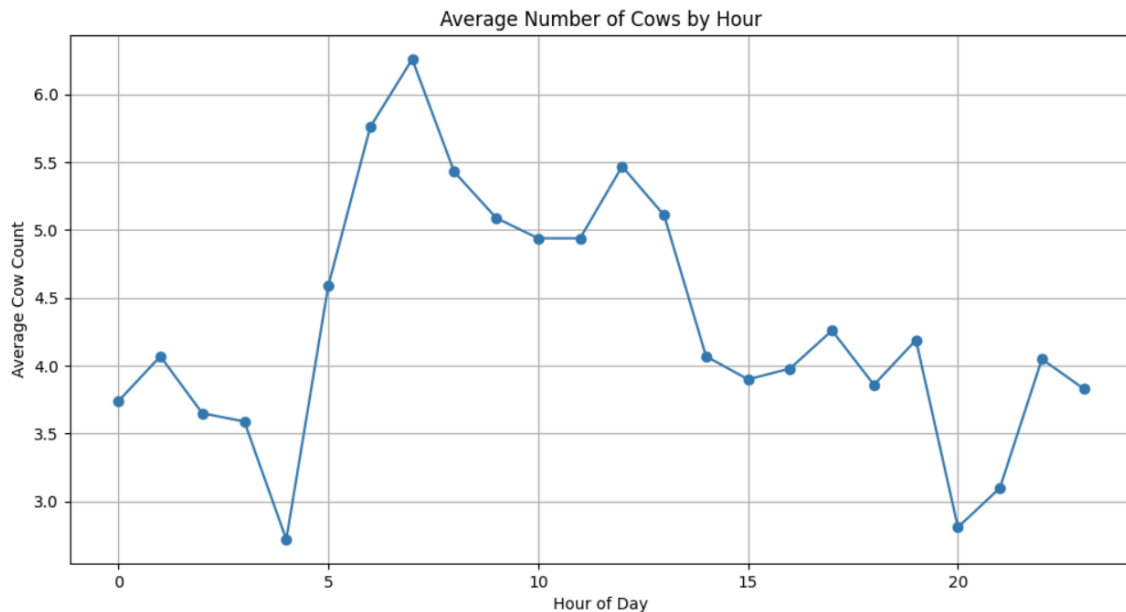
- ❖ Tasa de falsos negativos (esquina inferior izquierda): solo el 3% de las vacas reales no son detectadas. Representa una tasa de error muy baja en pérdida de detecciones.

Métrica	Inicio	Interpretación
Precisión	92%	92 de cada 100 detecciones son correctas
Recall	95%	Encuentra 95 de cada 100 vacas presentes
mAP50	95%	Excelente precisión con 50% IoU
mAP50-95	80%	Robusto en diferentes umbrales
F1-Score	93%	Alto balance entre precisión y recall

## 4.5 Validación de Objetivos


Los objetivos iniciales establecían dos umbrales: 80% de precisión para condiciones diurnas y 50% para condiciones nocturnas. El modelo que desarrollamos superó ambas metas al alcanzar un 92% de precisión general en todas las condiciones de iluminación, con una impresionante tasa de verdaderos positivos del 97% y solo un 3% de detecciones perdidas.

## 4.6 Hallazgos




Se obtuvo una media de la cantidad de vacas formadas cada hora del día, en la primera gráfica obtenida se ve que a las 4 a.m hay una caída de forma general todos los días a un promedio de una vaca formada nada más.

Después de la caída mencionada, hay un claro incremento en el transcurso de 3 hrs llegando a un promedio de 7 vacas formadas a las 7 a.m. Durante el resto del día hay una disminución de vacas formadas hasta caer en su segundo mínimo con dos vacas promedio a las 8 p.m. El patrón mencionado anteriormente se puede visualizar en esta segunda gráfica de distribución:




A lo largo de la mayoría de fechas se puede apreciar el mismo patrón. Ejemplos muy claros de dicho patrón pueden apreciarse específicamente en el día 2024-05-16 con mínimos

de 0 a lo largo de la 1 a.m y las 3 a.m, un máximo de 11 vacas a las 8 a.m y otra disminución extrema a 3 vacas a las 8 p.m. Y el día 2024-05-06 con mínimos de una vaca en la madrugada, un máximo de 10 vacas a las 9 a.m y una disminución a 3 vacas a las 8 p.m.

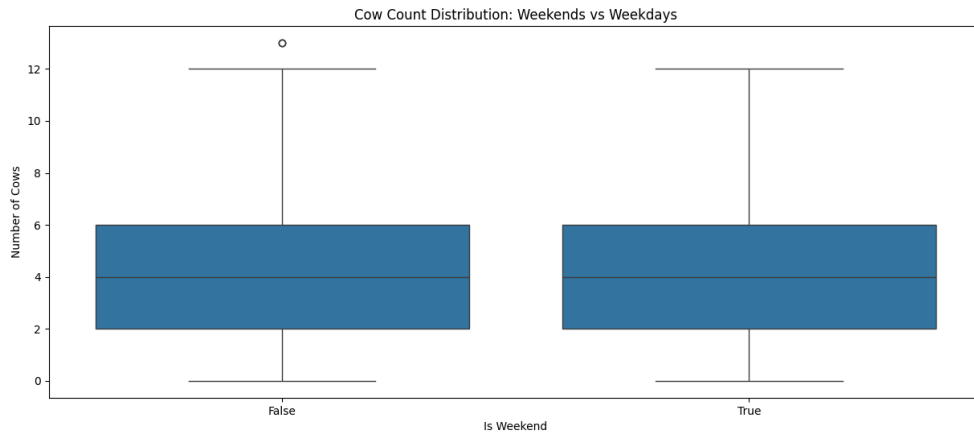


4.6.1 Hallazgos extra solicitados por el Socio Formador

Se solicitó buscar patrones entre semana y los fines de semana.



No se encontró diferencia significativa entre los 7 días de la semana.



Tampoco se ve una diferencia importante entre la cantidad de vacas promedio formada entre semana y los fines de semana, de hecho se ve casi igual.

## 5.0 Deployment

Entregamos el siguiente repositorio al socio formador.

<https://github.com/salgue441/caetec-cow-classification/tree/main>

En la siguiente liga se encuentra el manual entregado al socio formador Ivo, el cual lo aprobó al poder implementar exitosamente el modelo en una Raspberry Pi 3 B+.

[https://github.com/salgue441/caetec-cow-classification/blob/main/docs/guides/CowVision\\_%20Instalacio%CC%81n%20y%20despliegue.pdf](https://github.com/salgue441/caetec-cow-classification/blob/main/docs/guides/CowVision_%20Instalacio%CC%81n%20y%20despliegue.pdf)

### Manual de Instalación y Despliegue

Ivo Neftali Ayala García

To: +2 others

Sun 4/2

Ivo Neftali Ayala García

To: Benjamín Valdés Aguirre

Cc: +4 others

Sun 4/27/2025 9:31 PM

This message is in Spanish
 

Translate to English
 Never translate from Spanish

Buenas tardes,

No tuve ningún error durante la implementación.

Saludos

Ivo

This message is in Spanish
 

Translate to English
 Never translate from Spanish

Estimado Dr. Valdés,

Implementé exitosamente los modelos de los estudiantes en una Raspberry Pi 3 B+ y cuento con los manuales de instalación.

Agradezco el apoyo de ambos equipos en el desarrollo y puesta en marcha de los modelos.

Saludos

## 6.0 Comparación

En esta sección se realizará un análisis comparativo entre el modelo y los hallazgos entregados en el semestre previo, y aquellos correspondientes al modelo implementado oficialmente durante el deployment junto con el socio formador. Es importante destacar que no se recolectaron nuevos datos en este cambio de modelo. Para esta comparación se utilizó el dataset previamente disponible. Esto permite una comparación de los modelos más exacta al usar ambos el mismo dataset, pero puede llegar a limitar nuestro entendimiento de cómo le iría al modelo en otras condiciones. El análisis consiste prioritariamente en las métricas de rendimiento ya que el propósito del proyecto es el mismo. Luego se destaca porque también este nuevo modelo es una mejora al anterior.

### 6.1 Modelos

#### 6.1 Modelo Previo

Como se mencionó anteriormente en la sección 4 el modelo entregado el semestre anterior fue **YOLO versión 8x**, que representa una variante más potente y sofisticada de la familia de detectores YOLO. YOLOv8x utiliza una arquitectura de red neuronal convolucional profunda con aproximadamente 68.2 M de parámetros, diseñada para maximizar la precisión en tareas de detección de objetos, ofreciendo un rendimiento en términos de exactitud y confiabilidad.

#### 6.2 Modelo Actual

Para la entrega del modelo actual optamos por usar **YOLO versión 9c**, una variante eficiente y balanceada dentro de la familia de modelos YOLO. YOLOv9c incorpora una arquitectura moderna basada en mejoras estructurales como el uso de componentes C2f y el reparametrization technique, con aproximadamente 25.9 millones de parámetros. Este modelo está diseñado para mantener una alta precisión en la detección de objetos al mismo tiempo que reduce el consumo computacional, lo que lo hace especialmente adecuado para entornos donde se requiere procesamiento en tiempo real con recursos limitados. Considerando que este es nuestro caso este modelo sería más adecuado para nuestro cliente.

## 6.2 Resultados y Hallazgos

	F1		Precisión	
Modelo	Val	Test	Val	Test
YOLOv8x	0.93	0.93	92%	93%
YOLOv9c	0.93	0.93	93%	93%

Modelo	mAP50 (B)	mAP50-95 (B)
YOLOv8x	0.95	0.80
YOLOv9c	0.96	0.815

Las métricas más relevantes para evaluar el rendimiento son **mAP50 (B)** y **mAP50-95 (B)**. Ambas se basan en el cálculo de *mean Average Precision* (mAP), una medida que combina precisión y exhaustividad para evaluar qué tan bien el modelo detecta y localiza objetos dentro de una imagen.

### mAP50 (B)

- ❖ **Definición:** Es el promedio de precisión (AP) cuando se considera que una predicción es correcta si el *Intersection over Union* (IoU) entre el *bounding box* predicho y el real es al menos **0.50**.
- ❖ **Interpretación:** Evalúa si el modelo detecta correctamente los objetos con una tolerancia media en la superposición. Es útil para tener una idea general de qué tanto el modelo "atrapa" los objetos.
- ❖ **Resultados:** Un valor de **0.95** (YOLOv8x) o **0.96** (YOLOv9c) significa que el 95%–96% de los objetos fueron detectados con suficiente precisión espacial.


### mAP50-95 (B)

- ❖ **Definición:** Es el promedio de las precisiones (AP) calculadas para múltiples umbrales de IoU: desde **0.50 hasta 0.95**, en pasos de 0.05.
- ❖ **Interpretación:** Esta métrica es más exigente, ya que exige detecciones más precisas. Permite evaluar la capacidad del modelo no solo de encontrar los objetos, sino de localizarlos con precisión casi exacta.
- ❖ **Resultados:** Un valor de **0.80** (YOLOv8x) o **0.815** (YOLOv9c) indica que el modelo mantiene un alto rendimiento incluso con umbrales de localización más estrictos.


En término de los hallazgos siguen siendo practicamente los mismos el modelo actual comparado con el modelo previo.


- ❖ Cada día las vacas siguen el mismo patrón
  - **Punto Mínimo Matutino:** A las 4:00 AM se registra una caída significativa, llegando a un promedio de solo una vaca formada.
  - **Incremento Matutino:** Entre las 4:00 AM y 7:00 AM se observa un incremento notable:
    - Duración: 3 horas
    - Resultado: Alcanza un promedio de 7 vacas formadas a las 7:00 AM
  - **Descenso Gradual:** Durante el resto del día se presenta una disminución progresiva:
    - Culmina en un segundo punto mínimo a las 8:00 PM
    - Promedio de dos vacas formadas en este horario
- ❖ No se encontró diferencia significativa entre los 7 días de la semana.

Yolov8x



Yolov9c





## 6.3 Limitaciones y recomendaciones

A pesar de que el modelo tuvo una buena precisión con un dataset que incluía imágenes de ambos niveles de iluminación, es importante notar que este modelo no opera de manera óptima en condiciones nocturnas debido a limitaciones técnicas en la captura de imágenes. La calidad reducida de las imágenes nocturnas, caracterizada por iluminación insuficiente, mayor ruido digital y contrastes menos definidos, afecta la capacidad del modelo para mantener su máximo rendimiento. Igual se recomienda instalar algún tipo de bombillo o luz para que la cámara pueda captar de manera adecuada a las vacas. Considerando que la luz no afecta la rutina de las vacas sería de gran ayuda.

## 6.4 Conclusiones

- ❖ YOLOv8x es un modelo más grande y potente, pero no ofrece una ventaja significativa en precisión o F1.
- ❖ YOLOv9c logra igual o mejor rendimiento en todas las métricas clave y con menos de la mitad de parámetros, lo que implica menor demanda computacional.
- ❖ En un entorno de producción donde los recursos son limitados y se requiere eficiencia en tiempo real, YOLOv9c es claramente la mejor elección.



## **Bibliografía:**

Foundation, Raspberry Pi (2024). Raspberry Pi Performance Guidelines for Computer Vision. Version 2.1. url: <https://www.raspberrypi.com/documentation>.

Ultralytics. (2023). *YOLOV8*. <https://docs.ultralytics.com/es/models/yolov8/>

Ultralytics. (2024). *YOLOV9*. <https://docs.ultralytics.com/es/models/yolov9/>